
Devoir Maison

Analyse de Séries Temporelles

Audoin Sabrié

Table des matières

1	Analyse descriptive	3
2	Stationnarisation par estimation et modélisation	5
2.1	Identification et sélection du modèle ARMA	9
2.1.1	Identification visuelle	10
2.1.2	Sélection par critères d'information	10
2.1.3	Validation du modèle retenu	11
2.2	Modèle ARIMA(2,0,5) retenu	13
3	Modélisation d'un SARIMA	14
3.1	Analyse de la série différenciée Z_t	14
3.1.1	Analyse graphique	15
3.1.2	Fonction d'autocorrélation	16
3.2	Analyse descriptive de la stationnarité de Z_t	16
3.2.1	Test de Dickey-Fuller Augmenté sur Z_t	16
3.3	Estimation du modèle SARIMA	17
3.4	Performances prédictives du modèle SARIMA	19

1 Analyse descriptive




FIGURE 1 – Graphe de X_n en fonction de $n \leq 100$





FIGURE 2 – Graphe de X_n en fonction de n

FIGURE 3 – Graphe de l'ACF de X_n en fonction du lag

L'ACF de la série $(X_t)_{1 \leq t \leq 1000}$ présente une décroissance lente et reste positive, ce qui, d'après le cours, est caractéristique des modèles ARIMA. On soupçonne donc un processus de type ou SARIMA. On exclut par ailleurs l'hypothèse de bruit IID, puisque l'ACF n'est pas proche de 0 pour les lags strictement positifs.

L'analyse graphique de la série $(X_t)_{1 \leq t \leq 1000}$ révèle une tendance croissante : la moyenne de la série augmente au fil du temps, ce qui constitue une violation de la stationnarité en moyenne. De plus, l'ACF présente une décroissance très lente avec une structure périodique suggérant la présence d'une composante saisonnière. Ces deux éléments conduisent à **rejeter visuellement la stationnarité**.

Un premier test de Dickey-Fuller Augmenté (`adf.test`) rejette fortement l'hypothèse nulle de racine unitaire (p -value = 0.01). La série semble stationnaire au sens de ce test. Toutefois, l'analyse graphique suggère la présence d'une tendance déterministe, ce qui peut indiquer une stationnarité autour d'une tendance plutôt qu'une stationnarité stricte.

Afin de préciser ce diagnostic, nous mettons en place le test de Dickey-Fuller Augmenté avec tendance (`ur.df`, type `"trend"` du package `urca`), dont le modèle estimé est :

$$\Delta X_t = \mu + \beta t + \gamma X_{t-1} + \sum_{j=1}^p \delta_j \Delta X_{t-j} + \varepsilon_t \quad (1)$$

Ce test produit trois statistiques emboîtées :

— **tau3** = -19.93

$H_0 : \gamma = 0$ (racine unitaire) contre $H_1 : \gamma < 0$ (stationnarité).

Seuil critique à 5% : -3.41.

$-19.93 < -3.41 \Rightarrow$ **on rejette** H_0 : pas de racine unitaire.

— **phi3** = 198.69

$H_0 : \gamma = 0$ et $\beta = 0$ (racine unitaire et absence de tendance) contre H_1 : au moins

l'un des deux est non nul.

Seuil critique à 5% : 6.25.

$198.69 > 6.25 \Rightarrow$ **on rejette** H_0 : la tendance est bien présente.

— **phi2** = 132.47

$H_0 : \gamma = 0, \beta = 0$ et $\mu = 0$ (racine unitaire, absence de tendance et de constante) contre H_1 : au moins l'un des trois est non nul.

Seuil critique à 5% : 4.68.

$132.47 > 4.68 \Rightarrow$ **on rejette** H_0 : constante et/ou tendance significatives.

Les trois statistiques convergent vers la même conclusion : la série ne présente pas de racine unitaire, mais possède une **tendance déterministe linéaire significative**. On conclut que (X_t) est une série non stationnaire, mais le deviendra une fois débarrassée de sa tendance déterministe $m(t) = a + bt$ et de sa composante saisonnière $s(t)$.

2 Stationnarisation par estimation et modélisation

Estimation de la tendance et de la saisonnalité

Dans notre cas, si elle existe, la période est $d = 12$, qui est paire, donc $d = 2q = 12 \Rightarrow q = 6$. On utilise la moyenne mobile pondérée :

$$\hat{m}_t = \frac{0.5x_{t-6} + x_{t-5} + \dots + x_{t+5} + 0.5x_{t+6}}{12}, \quad 6 < t \leq n - 6$$

La composante saisonnière $\hat{s}_k$ est ensuite estimée en deux étapes. Pour chaque $k = 1, \dots, 12$, on calcule la moyenne w_k des déviations :

$$w_k = \text{moyenne} \{ (x_{k+jd} - \hat{m}_{k+jd}), \quad q < k + jd \leq n - q \}$$

Puis on corrige afin que les composantes saisonnières somment à zéro :

$$\hat{s}_k = w_k - \frac{\sum_{i=1}^{12} w_i}{12}$$

avec $\hat{s}_k = \hat{s}_{k-d}$ pour $k > d$.

Sous R, la fonction `decompose()` implémente exactement cette procédure :

La série désaisonnalisée et détrended est alors définie par :

$$Y_t = X_t - \hat{m}_t - \hat{s}_t$$

On peut même aller plus loin avec l'estimation d'un coefficient directeur et d'une ordonnée à l'origine pour $\hat{m}$ par l'estimateur des moindres carrés ordinaires grâce à **lm** sur R. Il en résulte que :

$$\hat{m}(t) = 0.010266t + 0.802962 \quad (2)$$

avec une significativité de toutes les variables estimées, par les tests de Student sur le modèle, ainsi que le test de Fisher.

$$\hat{s}(1) = 2.7219398, \quad \hat{s}(2) = 2.8525435, \quad (3)$$

$$\hat{s}(3) = 2.1229281, \quad \hat{s}(4) = 0.6459972, \quad (4)$$

$$\hat{s}(5) = -0.8112487, \quad \hat{s}(6) = -2.0104737, \quad (5)$$

$$\hat{s}(7) = -2.5314330, \quad \hat{s}(8) = -2.5511635, \quad (6)$$

$$\hat{s}(9) = -1.9488499, \quad \hat{s}(10) = -0.8622432, \quad (7)$$

$$\hat{s}(11) = 0.5810088, \quad \hat{s}(12) = 1.7909946 \quad (8)$$

Analyse de stationnarité de la série transformée Y_t




FIGURE 4 – Graphe de Y_n en fonction de $n \leq 100$





FIGURE 5 – Graphe de Y_n en fonction de n 

FIGURE 6 – Graphe issu de la fonction decompose de RStudio

On peut remarquer que la tendance estimée par R ne correspond pas exactement à une fonction affine, mais cela ne freine pas les travaux suivants. C'est d'ailleurs cette estimation non linéaire de R qui nous a encouragé à établir l'estimation par les MCO de cette fonction plus tôt.

FIGURE 7 – Graphe de l'ACF de Y_n en fonction du lagFIGURE 8 – Graphe de la PACF de Y_n en fonction du lag

On considère la série Y_t , obtenue après détrendage et désaisonnalisation de la série initiale. L'objectif est d'étudier sa stationnarité à l'aide d'outils graphiques et statistiques.

1. Analyse graphique de la série

La représentation de Y_t en fonction du temps montre que la série fluctue autour d'un axe horizontal, sans tendance apparente ni évolution structurelle de la moyenne.

Ainsi, on observe que :

- la moyenne semble constante au cours du temps ;
- les fluctuations apparaissent centrées autour de zéro ;
- aucune tendance déterministe n'est visible.

Ces éléments suggèrent une stationnarité en moyenne.

2. Fonction d'autocorrélation (ACF)

L'analyse de la fonction d'autocorrélation empirique montre une décroissance progressive des corrélations vers zéro, de manière approximativement exponentielle.

Plus précisément :

— elles décroissent rapidement en s'approchant de zéro ;

Ce comportement est caractéristique d'un processus stationnaire de type ARMA, et contraste avec une série non stationnaire où l'ACF décroîtrait lentement ou resterait élevée.

3. Test de Dickey-Fuller augmenté

On applique un test de Dickey-Fuller augmenté sur la série Y_t (après suppression des valeurs manquantes) :

H_0 : présence d'une racine unitaire (non-stationnarité)

H_1 : stationnarité

Les résultats obtenus sont :

— statistique de test : -18.292

— p-value : 0.01

On rejette l'hypothèse nulle.

4. Conclusion

L'ensemble des résultats (analyse graphique, ACF et test ADF) converge vers la même conclusion :

La série Y_t est stationnaire

La série présente des fluctuations autour d'une moyenne constante, une autocorrélation décroissante rapidement vers zéro, et ne présente pas de racine unitaire selon le test de Dickey-Fuller augmenté.

2.1 Identification et sélection du modèle ARMA

Afin d'identifier le modèle ARMA le plus adapté aux résidus $(Y_t)_{1 \leq t \leq 1000}$, nous procédons en deux étapes : une identification visuelle via l'ACF et la PACF, puis une sélection par critères d'information.

2.1.1 Identification visuelle

L'examen de la fonction d'autocorrélation (ACF) de Y_t révèle des pics significatifs aux lags 1, 2 et 3, les autocorrélations devenant non significatives à partir du lag 4 et restant à l'intérieur des bandes de confiance à 95%. La fonction d'autocorrélation partielle (PACF) présente le même comportement : des pics significatifs aux lags 1, 2 et 3, suivis d'une troncature nette.

Dans le cas d'un processus AR pur, on attendrait une ACF à décroissance progressive et une PACF tronquée. Dans le cas d'un MA pur, c'est l'inverse. Ici, les deux fonctions se tronquent simultanément, ce qui est caractéristique d'un processus ARMA(p, q) avec p et q faibles. L'identification visuelle suggère donc des ordres candidats $p, q \in \{1, 2, 3\}$.

2.1.2 Sélection par critères d'information

Afin de confirmer et préciser ce choix, nous estimons l'ensemble des modèles ARMA(p, q) pour $p, q \in \{0, \dots, 5\}$ et comparons leurs critères d'information AIC et BIC, définis par :

$$\text{AIC} = -2 \log(\hat{L}) + 2k \quad \text{BIC} = -2 \log(\hat{L}) + k \log(n) \quad (9)$$

où $\hat{L}$ est la vraisemblance maximisée, k le nombre de paramètres et $n = 1000$ la taille de l'échantillon. Le BIC pénalise davantage la complexité du modèle que l'AIC.

	Modele	AIC	BIC
1	ARIMA(1,0,0)	2957.811	2972.498
2	ARIMA(1,0,1)	2883.007	2902.590
3	ARIMA(1,0,2)	2744.296	2768.775
4	ARIMA(1,0,3)	2499.138	2528.512
5	ARIMA(1,0,4)	2400.365	2434.635
6	ARIMA(1,0,5)	2374.101	2413.266
7	ARIMA(2,0,0)	2749.568	2769.151
8	ARIMA(2,0,1)	2396.770	2421.248
9	ARIMA(2,0,2)	2618.864	2648.238
10	ARIMA(2,0,3)	2313.616	2347.886
11	ARIMA(2,0,4)	2307.272	2346.438
12	ARIMA(2,0,5)	2232.528	2276.589
13	ARIMA(3,0,0)	2548.764	2573.243
14	ARIMA(3,0,1)	2550.284	2579.658
15	ARIMA(3,0,2)	2382.452	2416.722
16	ARIMA(3,0,3)	2314.050	2353.216
17	ARIMA(3,0,4)	2280.464	2324.525
18	ARIMA(3,0,5)	2226.127	2275.084

19	ARIMA(4,0,0)	2550.486	2579.860
20	ARIMA(4,0,1)	2551.957	2586.227
21	ARIMA(4,0,2)	2350.966	2390.132
22	ARIMA(4,0,3)	2301.256	2345.317
23	ARIMA(4,0,4)	2229.829	2278.786
24	ARIMA(4,0,5)	2231.576	2285.428
25	ARIMA(5,0,0)	2540.829	2575.099
26	ARIMA(5,0,1)	2315.337	2354.503
27	ARIMA(5,0,2)	2523.949	2568.010
28	ARIMA(5,0,3)	2292.560	2341.517
29	ARIMA(5,0,4)	2234.778	2288.631
30	ARIMA(5,0,5)	2228.640	2287.388

L'ARIMA(3,0,5) minimise simultanément l'AIC et le BIC. On remarque que tous les modèles compétitifs comportent 7 à 8 paramètres, ce qui indique que la structure de Y_t requiert effectivement des ordres plus élevés que ce que suggérerait l'identification visuelle. Le principe de parcimonie est ici respecté dans le sens où l'on ne retient pas de paramètres superflus : les critères d'information pénalisent la complexité et convergent vers le même modèle.

2.1.3 Validation du modèle retenu

Le modèle ARIMA(3,0,5) est estimé sous R.

Le test de Ljung-Box (porte-manteau corrigé) est appliqué aux résidus afin de vérifier qu'ils constituent bien un bruit blanc :

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_h = 0 \quad (\text{pas d'autocorrélation résiduelle}) \quad (10)$$

Test	Statistique	p-value	Conclusion
Ljung-Box (lag = 24)	13.05	0.669	Ne rejette pas H_0
Ljung-Box (lag = 20)	7.73	0.994	Ne rejette pas H_0

TABLE 1 – Tests de Ljung-Box sur les résidus de l'ARIMA(3,0,5)

Les deux tests ne rejettent pas H_0 à aucun seuil usuel. On conclut que les résidus du modèle ARIMA(3,0,5) constituent bien un bruit blanc : le modèle a capté l'intégralité de la structure d'autocorrélation de Y_t . Le modèle ARIMA(3,0,5) estimé s'écrit :

$$Y_t = 1.5485 Y_{t-1} - 0.9476 Y_{t-2} + 0.2276 Y_{t-3} + \varepsilon_t - 1.2683 \varepsilon_{t-1} + 0.3069 \varepsilon_{t-2} - 0.5626 \varepsilon_{t-3} + 0.2995 \varepsilon_{t-4}$$

$$+ 0.2250 \varepsilon_{t-5}$$

(11)

où $\varepsilon_t \sim \text{BRUITBLANC}(0, \hat{\sigma}^2)$ non corrélés avec $\hat{\sigma}^2 = 0.5392$.

Afin d'évaluer ou vérifier la cohérence ainsi que les performances prédictives du modèle, nous procédons à une validation type Leave 100 Out : le modèle est réestimé sur les 900 premières observations, puis utilisé pour prédire les 100 suivantes ($t = 901, \dots, 1000$), dont les vraies valeurs sont connues. Les agrégats d'erreur obtenus sont :

Métrique	Valeur
RMSE	1.269
MAE	0.971

TABLE 2 – Performances prédictives du modèle ARIMA(3,0,5) sur $t = 901, \dots, 1000$

Ces résultats indiquent une erreur moyenne d'environ 1 unité sur une série d'amplitude 20, soit une erreur relative d'environ 5%. Le RMSE légèrement supérieur au MAE suggère la présence de quelques erreurs ponctuelles plus importantes, sans outliers majeurs. Ces performances semblent satisfaisantes compte tenu de l'horizon de prédiction de 100 pas.




FIGURE 9 – Prédictions des valeurs 901 : 1000 sur les observations 1 : 900

Attention, le modèle spécifié ARMA(3,5) se trouve ne pas être inversible : on peut se tourner vers le modèle ARMA(2,5) ou (4,4) pour ce travail

Modèle	AIC	BIC	Causal	Inversible	Ljung-Box
ARIMA(3,0,5)	2226.1	2275.1	✓	×	✓
ARIMA(2,0,5)	2232.5	2276.6	✓	✓	✓
ARIMA(4,0,4)	2229.8	2278.8	✓	✓	✓
ARIMA(2,0,3)	2313.6	2347.9	✓	≈	×

TABLE 3 – Comparaison des modèles ARIMA candidats

Nous procédons ainsi à un Leave 100 Out pour départager ces trois sur leur capacité prédictive. En effet, l'un performe sur le critère AIC, et est inversible causal, l'autre performe le plus sur le critère BIC, et est inversible causal, et le dernier performe sur AIC et BIC, mais n'est pas inversible. Comme plus tôt pour l'ARMA(3,5) nous utilisons les 900 premières valeurs pour prédire les 100 suivantes et comparer avec les 100 suivantes connues.

Modèle	AIC	BIC	Causal	Inversible	RMSE	MAE
ARIMA(3,0,5)	2226.1	2275.1	✓	×	1.2543	0.9505
ARIMA(2,0,5)	2232.5	2276.6	✓	✓	1.2543	0.9503
ARIMA(4,0,4)	2229.8	2278.8	✓	✓	1.2543	0.9511

TABLE 4 – Comparaison finale des modèles ARIMA candidats

Les performances prédictives des trois modèles candidats, évaluées par backtesting sur $(X_t)_{901 \leq t \leq 1000}$, sont quasiment identiques : les valeurs de RMSE et MAE sont indiscernables à quatre décimales près. Le backtesting ne permet donc pas à lui seul de discriminer les modèles.

En l'absence de différence prédictive significative, le critère de départage devient la validité théorique. L'ARIMA(3,0,5), bien que minimisant l'AIC et le BIC, présente une racine du polynôme MA de module $0.813 < 1$, ce qui implique que le processus est non inversible.

Les modèles ARIMA(2,0,5) et ARIMA(4,0,4) sont tous deux causaux et inversibles. On retient l'**ARIMA(2,0,5)** au nom du principe de parcimonie : il comporte 7 paramètres contre 8 pour l'ARIMA(4,0,4), présente le meilleur MAE parmi les modèles théoriquement valides (0.9503), et ses performances prédictives sont indiscernables de celles de l'ARIMA(3,0,5).

2.2 Modèle ARIMA(2,0,5) retenu

Le modèle ARIMA(2, 0, 5) estimé s'écrit :

$$Y_t = 1.2646 Y_{t-1} - 0.5094 Y_{t-2} + \varepsilon_t - 1.0269 \varepsilon_{t-1} - 0.0027 \varepsilon_{t-2} - 0.5110 \varepsilon_{t-3} + 0.1781 \varepsilon_{t-4} + 0.3627 \varepsilon_{t-5} \quad (12)$$

où $\varepsilon_t \sim \text{BRUITBLANC}(0, \hat{\sigma}^2)$ avec $\hat{\sigma}^2 = 0.5433$.

L'enjeu de la prédiction va être de prédire les nouvelles valeurs de Y auxquelles nous allons ajouter la tendance prédite (régression linéaire et mentionnée plus tôt), et la saison, tout en restant vigilant à bien faire coïncider $s(5)$ avec le terme 1001, ce terme étant congru à 5 modulo 12. Nous noterons que dans le procédé de prédiction, nous devons prédire 106 valeurs pour Y_t afin de faire coïncider le modèle : ARMA dépendant des valeurs précédentes pour les nouvelles valeurs. Le fichier des prédictions contient toutefois les 100 dernières valeurs prédites pour X_t .




FIGURE 10 – Graphe de la série originale en noir, et prédiction en rouge

Les prédictions reproduisent la tendance croissante et la saisonnalité de période 12. Comme attendu pour un modèle ARMA, la variabilité stochastique des prédictions diminue à mesure que le temps passe, les prévisions s'approchant progressivement vers la composante déterministe $\hat{m}_t + \hat{s}_t$.

3 Modélisation d'un SARIMA

3.1 Analyse de la série différenciée Z_t

On définit le processus $(Z_t)_{1 \leq t \leq 1000-d}$ par différenciation saisonnière d'ordre $d = 12$:

$$Z_t := \nabla_{12} X_t = (I - B^{12}) X_t = X_t - X_{t-12}, \quad 12 \leq t \leq 1000 \quad (13)$$

où B désigne l'opérateur retard tel que $B^{12}X_t = X_{t-12}$. Cette transformation élimine simultanément la tendance déterministe et la composante saisonnière de période 12.

3.1.1 Analyse graphique

Les 100 premières valeurs de (Z_t) sont représentées ci-dessous :




FIGURE 11 – Graphe des 100 premières valeurs de $(Z_t)_{1 \leq t \leq 988}$

La série complète $(Z_t)_{1 \leq t \leq 988}$ est représentée ci-dessous :




FIGURE 12 – Graphe des 988 valeurs de $(Z_t)_{1 \leq t \leq 988}$

3.1.2 Fonction d'autocorrélation




FIGURE 13 – Fonction d'autocorrélation de $(Z_t)_{1 \leq t \leq 988}$

3.2 Analyse descriptive de la stationnarité de Z_t

L'analyse graphique de $(Z_t)_{1 \leq t \leq 988}$ suggère une stationnarité de la série. Deux éléments visuels appuient cette conclusion.

D'une part, la série semble osciller autour d'une valeur constante proche de 0, sans tendance croissante ou décroissante apparente (voir Figure 12). La différenciation saisonnière d'ordre 12 a donc bien éliminé la tendance déterministe présente dans (X_t) .

D'autre part, la fonction d'autocorrélation (voir Figure 14) présente une chute très rapide vers 0 dès les premiers lags, les autocorrélations restant à l'intérieur des bandes de confiance à 95% pour les lags suivants. Ce comportement est caractéristique d'un processus stationnaire, par opposition à la décroissance lente observée sur l'ACF de (X_t) .

Ces observations conduisent à **ne pas rejeter visuellement la stationnarité** de (Z_t) . La différenciation saisonnière $Z_t = X_t - X_{t-12}$ s'avère donc suffisante pour stationnariser la série (X_t) .

3.2.1 Test de Dickey-Fuller Augmenté sur Z_t

Afin de confirmer l'analyse visuelle, nous appliquons le test de Dickey-Fuller Augmenté avec tendance (`ur.df`, type `"trend"`) sur la série différenciée (Z_t) . Le modèle estimé est :

$$\Delta Z_t = \mu + \beta t + \gamma Z_{t-1} + \sum_{j=1}^p \delta_j \Delta Z_{t-j} + \varepsilon_t \quad (14)$$

Les résultats sont les suivants :

Statistique	Valeur	Seuil critique 5%	Décision
tau3	-19.167	-3.41	Rejette H_0
phi2	122.459	4.68	Rejette H_0
phi3	183.687	6.25	Rejette H_0

TABLE 5 – Résultats du test ADF avec tendance sur (Z_t)

Les trois statistiques rejettent leurs hypothèses nulles respectives au seuil de 1%. On conclut à l'absence de racine unitaire dans (Z_t) .

Contrairement à (X_t) , la série (Z_t) ne présente donc **aucune tendance déterministe** : la différenciation saisonnière d'ordre 12 a intégralement éliminé la structure non stationnaire de la série originale.

On conclut que (Z_t) est **stationnaire**, ce qui valide l'approche par différenciation saisonnière et justifie la modélisation de (X_t) par un processus SARIMA avec $D = 1$.

3.3 Estimation du modèle SARIMA

Pour l'estimations des paramètres associés au modèle SARIMA, nous procéderons comme avant pour le modèle ARMA. Nous sélectionnerons sur critère AIC et BIC.

TOP 10 AIC :

	p	q	P	Q	AIC	BIC
62	3	3	0	1	2795.225	2834.390
64	3	3	1	1	2796.988	2841.049
42	2	2	0	1	2916.004	2945.378
58	3	2	0	1	2916.394	2950.664
46	2	3	0	1	2916.916	2951.185
44	2	2	1	1	2917.164	2951.434
60	3	2	1	1	2917.582	2956.747
48	2	3	1	1	2918.038	2957.204
30	1	3	0	1	2938.192	2967.566
32	1	3	1	1	2939.936	2974.206

TOP 10 BIC :

	p	q	P	Q	AIC	BIC
62	3	3	0	1	2795.225	2834.390
64	3	3	1	1	2796.988	2841.049
42	2	2	0	1	2916.004	2945.378

58	3	2	0	1	2916.394	2950.664
46	2	3	0	1	2916.916	2951.185
44	2	2	1	1	2917.164	2951.434
60	3	2	1	1	2917.582	2956.747
48	2	3	1	1	2918.038	2957.204
14	0	3	0	1	2940.127	2964.606
30	1	3	0	1	2938.192	2967.566

On remarque que les deux premiers modèles de chaque liste sont identiques, et un saut AIC (+120), BIC(+100) se produit du passage du deuxième au troisième. Nos candidats sont donc les modèles SARIMA(3,0,3)(0,1,1) et SARIMA(3,0,3)(1,1,1). Le principe de parcimonie nous encourage à choisir le premier : SARIMA(3,0,3)(0,1,1).

Itérons la boucle avec davantage de modèles :

TOP 10 AIC :

	p	q	P	Q	AIC	BIC
188	3	3	0	1	2795.225	2834.390
189	3	3	0	2	2796.702	2840.763
191	3	3	1	1	2796.988	2841.049
237	4	3	0	1	2797.113	2841.175
195	3	4	0	1	2797.545	2841.606
281	5	3	0	1	2798.030	2846.987
238	4	3	0	2	2798.662	2847.619
241	4	4	0	1	2798.886	2847.843
198	3	4	1	1	2798.955	2847.912
196	3	4	0	2	2798.978	2847.935

TOP 10 BIC :

	p	q	P	Q	AIC	BIC
188	3	3	0	1	2795.225	2834.390
189	3	3	0	2	2796.702	2840.763
191	3	3	1	1	2796.988	2841.049
237	4	3	0	1	2797.113	2841.175
195	3	4	0	1	2797.545	2841.606
281	5	3	0	1	2798.030	2846.987
238	4	3	0	2	2798.662	2847.619
241	4	4	0	1	2798.886	2847.843
198	3	4	1	1	2798.955	2847.912

196 3 4 0 2 2798.978 2847.935

Le SARIMA(3,0,3)(0,1,1) revient à nouveau comme grand vainqueur, ce qui confirme notre position.

Le test de Box-Ljung(porte-manteau corrigé) appliqué aux résidus du modèle SARIMA donne une statistique de test de $X^2 = 9.4017$ avec 20 degrés de liberté, et une p-valeur associée de 0.9778.

Étant donné que la p-valeur est largement supérieure au seuil usuel de 5%, nous ne rejetons pas l'hypothèse nulle. On en conclut que les résidus peuvent être considérés comme un bruit blanc.

De plus, ce modèle est qualifié de causal(AR) et inversible sur sa partie MA et MA-saisonnnière : bonne nouvelle !

Le modèle s'écrit alors comme suit pour le $SARIMA(3, 0, 3)(0, 1, 1)_{12}$:

$$\begin{aligned} X_t = & 1.4676922 X_{t-1} - 0.9020843 X_{t-2} + 0.4343920 X_{t-3} \\ & + \varepsilon_t - 0.6798450 \varepsilon_{t-1} + 0.3257291 \varepsilon_{t-2} - 0.6416249 \varepsilon_{t-3} \\ & - 0.9880742 \varepsilon_{t-s} \end{aligned}$$

3.4 Performances prédictives du modèle SARIMA




FIGURE 14 – Leave 100 Out ARMA(2,5) vs SARIMA

Il est difficile de choisir entre les deux modèles pour ce qui est de leur qualité de prédiction. L'aspect déterministe de la saison - qui n'évolue pas en fonction du temps - rend l'ARMA aussi compétitif que le SARIMA dans ce cas là.

	Model	MAE	RMSE
1	SARIMA	0.9564267	1.259502
2	ARMA	0.9538286	1.255038

Il semble que l'ARMA est quelque peu meilleur sur cet échantillon lorsqu'il s'agit de prédire, compte tenu d'un RMSE et MAE plus faibles. Toutefois, on sait que le SARIMA nous a demandé moins d'étapes pour en arriver à prédire. Tout est davantage automatisé que la détrendisation + désaisonalisation qui est advenue dans l'ARMA. On préférera le SARIMA pour sa simplicité et l'accessibilité, l'ARMA pour ses prédictions en ce sens.

Nous pouvons réaliser une telle comparaison sur plusieurs fenêtres de données d'entraînement, et établir une moyenne des RMSE / MAE de chacun des modèles afin de conclure. Fenêtres glissantes : entraînement de 1 à 500 :900 par pas de 50

=== MOYENNES ROLLING FORECAST ===

SARIMA - RMSE moyen : 1.357503

SARIMA - MAE moyen : 1.083363

ARMA - RMSE moyen : 1.353634

ARMA - MAE moyen : 1.078197

Le modèle ARMA semble meilleur sous ce critère, accumulant des erreurs plus faibles lors des prédictions - bien que l'écart se joue à quelques centièmes.

Code utilisé :

```
plot(serie$V1[1:100], serie$V2[1:100],
     main = "Graphe de X_n en fonction de n",
     xlab = "n",
     ylab = "X_n",
     pch=20)

acf(serie$V2,
    main="Graphe de l'ACF de X_n en fonction du lag",
    xlab = "Lag",
    ylab = "ACF", lag.max=100)

library(tseries)
```

```
adf.test(serie$V2)
library(urca)
summary(ur.df(serie$V2, type = "trend", selectlags = "AIC"))

serie_ts <- ts(serie$V2, frequency = 12)
decomp <- decompose(serie_ts, type = "additive")

m_hat <- decomp$trend
s_hat <- decomp$seasonal
Y      <- decomp$random

plot(decomp)
print(m_hat)

serie$V3 = Y

plot(serie$V1[1:100], serie$V3[1:100],
     main = "Graphe de  $Y_n = X_n - \hat{m}_n - \hat{s}_n$ ",
     xlab = "n",
     ylab = " $Y_n$ ",
     pch = 19)

acf(na.omit(serie$V3),
    main="Graphe de l'ACF de  $Y_n$  en fonction du lag",
    xlab = "Lag",
    ylab = "ACF", lag.max=100)

library(tseries)
adf.test(na.omit(serie$V3))

serie$V4 = m_hat
serie$V5 = s_hat

lm1 = lm(na.omit(serie$V4) ~ serie$V1[7:994])
```

```

summary(lm1)

best_aic <- Inf
best_orderaic <- c(0,0)

for (p in 0:10) {
  for (q in 0:10) {
    fit <- try(arima(na.omit(serie$V3), order = c(p,0,q)), silent = TRUE)

    if (!inherits(fit, "try-error")) {
      if (fit$aic < best_aic) {
        best_aic <- fit$aic
        print(fit$aic,best_orderaic)
        best_orderaic <- c(p,q)
      }
    }
  }
}

AICS=c(
  arima(na.omit(serie$V3), order = c(1,0,0))$aic,
  arima(na.omit(serie$V3), order = c(1,0,1))$aic,
  arima(na.omit(serie$V3), order = c(1,0,2))$aic,
  arima(na.omit(serie$V3), order = c(1,0,3))$aic,
  arima(na.omit(serie$V3), order = c(1,0,4))$aic,
  arima(na.omit(serie$V3), order = c(1,0,5))$aic,

  arima(na.omit(serie$V3), order = c(2,0,0))$aic,
  arima(na.omit(serie$V3), order = c(2,0,1))$aic,
  arima(na.omit(serie$V3), order = c(2,0,2))$aic,
  arima(na.omit(serie$V3), order = c(2,0,3))$aic,
  arima(na.omit(serie$V3), order = c(2,0,4))$aic,
  arima(na.omit(serie$V3), order = c(2,0,5))$aic,

```

```

arima(na.omit(serie$V3), order = c(3,0,0))$aic,
arima(na.omit(serie$V3), order = c(3,0,1))$aic,
arima(na.omit(serie$V3), order = c(3,0,2))$aic,
arima(na.omit(serie$V3), order = c(3,0,3))$aic,
arima(na.omit(serie$V3), order = c(3,0,4))$aic,
arima(na.omit(serie$V3), order = c(3,0,5))$aic,

```

```

arima(na.omit(serie$V3), order = c(4,0,0))$aic,
arima(na.omit(serie$V3), order = c(4,0,1))$aic,
arima(na.omit(serie$V3), order = c(4,0,2))$aic,
arima(na.omit(serie$V3), order = c(4,0,3))$aic,
arima(na.omit(serie$V3), order = c(4,0,4))$aic,
arima(na.omit(serie$V3), order = c(4,0,5))$aic,

```

```

arima(na.omit(serie$V3), order = c(5,0,0))$aic,
arima(na.omit(serie$V3), order = c(5,0,1))$aic,
arima(na.omit(serie$V3), order = c(5,0,2))$aic,
arima(na.omit(serie$V3), order = c(5,0,3))$aic,
arima(na.omit(serie$V3), order = c(5,0,4))$aic,
arima(na.omit(serie$V3), order = c(5,0,5))$aic)

```

```

min(AICS)

```

```

BICS = c(BIC(
  arima(na.omit(serie$V3), order = c(1,0,0))),
  BIC(arima(na.omit(serie$V3), order = c(1,0,1))),
  BIC(arima(na.omit(serie$V3), order = c(1,0,2))),
  BIC(arima(na.omit(serie$V3), order = c(1,0,3))),
  BIC(arima(na.omit(serie$V3), order = c(1,0,4))),
  BIC(arima(na.omit(serie$V3), order = c(1,0,5))),

```

```

  BIC(arima(na.omit(serie$V3), order = c(2,0,0))),
  BIC(arima(na.omit(serie$V3), order = c(2,0,1))),
  BIC(arima(na.omit(serie$V3), order = c(2,0,2))),
  BIC(arima(na.omit(serie$V3), order = c(2,0,3))),
  BIC(arima(na.omit(serie$V3), order = c(2,0,4))),

```

```

BIC(arima(na.omit(serie$V3), order = c(2,0,5))),

BIC(arima(na.omit(serie$V3), order = c(3,0,0))),
BIC(arima(na.omit(serie$V3), order = c(3,0,1))),
BIC(arima(na.omit(serie$V3), order = c(3,0,2))),
BIC(arima(na.omit(serie$V3), order = c(3,0,3))),
BIC(arima(na.omit(serie$V3), order = c(3,0,4))),
BIC(arima(na.omit(serie$V3), order = c(3,0,5))),

BIC(arima(na.omit(serie$V3), order = c(4,0,0))),
BIC(arima(na.omit(serie$V3), order = c(4,0,1))),
BIC(arima(na.omit(serie$V3), order = c(4,0,2))),
BIC(arima(na.omit(serie$V3), order = c(4,0,3))),
BIC(arima(na.omit(serie$V3), order = c(4,0,4))),
BIC(arima(na.omit(serie$V3), order = c(4,0,5))),

BIC(arima(na.omit(serie$V3), order = c(5,0,0))),
BIC(arima(na.omit(serie$V3), order = c(5,0,1))),
BIC(arima(na.omit(serie$V3), order = c(5,0,2))),
BIC(arima(na.omit(serie$V3), order = c(5,0,3))),
BIC(arima(na.omit(serie$V3), order = c(5,0,4))),
BIC(arima(na.omit(serie$V3), order = c(5,0,5) )) )

print(BICS)
min(BICS)

tableau <- expand.grid(
  q = 0:5,
  p = 1:5
)

tableau$d <- 0

```



```
tableau$Modele <- paste0(
  "ARIMA(",
  tableau$p, ",",
  tableau$d, ",",
  tableau$q, ")"
)

tableau$AIC <- AICS
tableau$BIC <- BICS

tableau <- tableau[, c("Modele", "AIC", "BIC")]

print(tableau)

Y_ts <- ts(na.omit(serie$V3), frequency = 1)
pacf(Y_ts, lag.max = 30,
      main = "PACF des résidus Y_n en fonction du lag",
      xlab = "Lag",
      ylab = "PACF")

mod_final <- arima(na.omit(serie$V3), order=c(3,0,5))
checkresiduals(mod_final)
Box.test(residuals(mod_final), lag=20, type="Ljung-Box")

acf(residuals(mod_final), lag.max=30,
    main="ACF des résidus de l'ARIMA(3,0,5)")

phi <- c(1, -1.5485, 0.9476, -0.2276)
racines_AR <- polyroot(phi)
cat("Racines AR :\n")
print(Mod(racines_AR))

theta <- c(1, -1.2683, 0.3069, -0.5626, 0.2995)
racines_MA <- polyroot(theta)
cat("Racines MA :\n")
print(Mod(racines_MA))
```

```
mod_225 <- arima(Y, order=c(2,0,5))
print(Mod(polyroot(c(1, -mod_225$coef[1:2]))))
print(Mod(polyroot(c(1, mod_225$coef[3:7]))))

mod_404 <- arima(Y, order=c(4,0,4))
print(Mod(polyroot(c(1, -mod_404$coef[1:4]))))
print(Mod(polyroot(c(1, mod_404$coef[5:8]))))

Box.test(residuals(mod_225), lag=20, type="Ljung-Box")
Box.test(residuals(mod_404), lag=20, type="Ljung-Box")

mod_203 <- arima(Y, order=c(2,0,3))

cat("ARIMA(2,0,3) - AIC :", AIC(mod_203), "\n")
cat("ARIMA(2,0,3) - BIC :", BIC(mod_203), "\n")

racines_AR_203 <- Mod(polyroot(c(1, -mod_203$coef[1:2])))
cat("Racines AR :", racines_AR_203, "\n")
cat("Causal :", all(racines_AR_203 > 1), "\n")

racines_MA_203 <- Mod(polyroot(c(1, mod_203$coef[3:5])))
cat("Racines MA :", racines_MA_203, "\n")
cat("Inversible :", all(racines_MA_203 > 1), "\n")

Box.test(residuals(mod_203), lag=20, type="Ljung-Box")

backtest <- function(ordre, Y, serie){

  Y_train <- Y[1:894]

  mod <- arima(Y_train, order=ordre)

  pred <- predict(mod, n.ahead=106)
```

```

Y_pred <- as.numeric(pred$pred)[7:106]

# Tendence et saisonnalité
serie_train <- serie$V2[1:900]
serie_ts_train <- ts(serie_train, frequency=12)
decomp_train <- decompose(serie_ts_train, type="additive")
m_train <- as.numeric(decomp_train$trend)
s_train <- as.numeric(decomp_train$seasonal)

t_connu_train <- 7:894
modele_tendance_train <- lm(m_train[7:894] ~ t_connu_train)
t_future_train <- 901:1000
m_pred <- as.numeric(predict(modele_tendance_train,
                             newdata=data.frame(t_connu_train=t_future_train)))

s_values <- s_train[1:12]
s_pred <- s_values[(t_future_train - 1) %% 12 + 1]

X_pred <- m_pred + s_pred + Y_pred
X_vrai <- serie$V2[901:1000]

RMSE <- sqrt(mean((X_pred - X_vrai)^2))
MAE <- mean(abs(X_pred - X_vrai))

cat("ARIMA(", ordre, ") - RMSE :", RMSE, "| MAE :", MAE, "\n")
}

backtest(c(3,0,5), Y, serie)
backtest(c(2,0,5), Y, serie)
backtest(c(4,0,4), Y, serie)

mod_final <- arima(Y, order = c(2, 0, 5))
summary(mod_final)

Y <- na.omit(serie$V3)
mod_final <- arima(Y, order = c(2, 0, 5))

```

```
pred <- predict(mod_final, n.ahead = 106)
Y_pred <- as.numeric(pred$pred)[7:106]

t_connu <- 7:994
m_connu <- serie$V4[7:994]
modele_tendance <- lm(m_connu ~ t_connu)

t_future <- 1001:1100
m_pred <- as.numeric(predict(modele_tendance,
                             newdata = data.frame(t_connu = t_future)))

s_values <- as.numeric(serie$V5[1:12])
s_pred <- s_values[(t_future - 1) %% 12 + 1]

X_pred <- m_pred + s_pred + Y_pred

cat("Longueur X_pred :", length(X_pred), "\n")
cat("NA dans X_pred :", sum(is.na(X_pred)), "\n")
head(data.frame(t_future, X_pred))

output <- data.frame(t_future, X_pred)
write.table(output,
            file      = "???",
            row.names = FALSE,
            col.names = FALSE,
            sep       = " ")

print(X_pred)

plot(serie$V1, serie$V2, type="l",
     xlim=c(800, 1100),
     main="Série originale + prédictions",
     xlab="t", ylab="X_t")
lines(t_future, X_pred, col="red", lwd=2)
legend("topleft", legend=c("Série originale", "Prédictions"),
      col=c("black", "red"), lty=1)
```

```
serie_train <- serie$V2[1:900]
serie_ts_train <- ts(serie_train, frequency = 12)
decomp_train <- decompose(serie_ts_train, type = "additive")

m_train <- as.numeric(decomp_train$trend)      # NA sur 1:6 et 895:900
s_train <- as.numeric(decomp_train$seasonal)

Y_train <- as.numeric(na.omit(serie_train - m_train - s_train))

mod_train <- arima(Y_train, order = c(3, 0, 5))

pred_train <- predict(mod_train, n.ahead = 100)
Y_pred_train <- as.numeric(pred_train$pred)

t_connu_train <- 7:894
m_connu_train <- m_train[7:894]
modele_tendance_train <- lm(m_connu_train ~ t_connu_train)

t_future_train <- 901:1000
m_pred_train <- as.numeric(predict(modele_tendance_train,
                                   newdata = data.frame(t_connu_train = t_future_train)))

s_values_train <- s_train[1:12]
s_pred_train <- s_values_train[(t_future_train - 1) %% 12 + 1]

X_pred_train <- m_pred_train + s_pred_train + Y_pred_train

X_vrai <- serie$V2[901:1000]

RMSE <- sqrt(mean((X_pred_train - X_vrai)^2))
MAE <- mean(abs(X_pred_train - X_vrai))

cat("RMSE :", RMSE, "\n")
```

```
cat("MAE  :", MAE,  "\n")

plot(901:1000, X_vrai, type="l", col="black",
     main="Prédictions vs vraies valeurs (t = 901:1000)",
     xlab="t", ylab="X_t")
lines(901:1000, X_pred_train, col="red", lwd=2)
legend("topleft", legend=c("Vraies valeurs", "Prédictions"),
     col=c("black", "red"), lty=1)
```

```
Z <- diff(serie$V2, lag = 12)
```

```
plot(1:100, Z[1:100], type="l",
     main="Graphe des 100 premières valeurs de Z_t",
     xlab="t", ylab="Z_t")
```

```
plot(1:1000, Z[1:1000], type="l",
     main="Graphe des 1000 premières valeurs de Z_t",
     xlab="t", ylab="Z_t")
```

```
# ACF
acf(Z, lag.max=50,
    main="ACF de Z_t",
    xlab="Lag", ylab="ACF")
```

```
library(urca)
summary(ur.df(Z, type="trend", selectlags="AIC"))
```

```
# ACF et PACF de Z_t
acf(Z, lag.max = 50,
    main = "ACF de Z_t",
    xlab = "Lag", ylab = "ACF")
```

```

pacf(as.numeric(Z), lag.max = 50,
     main = "PACF de Z_t",
     xlab = "Lag", ylab = "PACF")

library(forecast)

resultats_sarima <- data.frame()

for(p in 0:5){
  for(q in 0:5){
    for(P in 0:2){
      for(Q in 0:2){
        tryCatch({
          mod <- Arima(serie$V2,
                      order      = c(p, 0, q),
                      seasonal = list(order = c(P, 1, Q), period = 12))
          resultats_sarima <- rbind(resultats_sarima,
                                    data.frame(p, q, P, Q,
                                              AIC = AIC(mod),
                                              BIC = BIC(mod)))
        }, error = function(e) NULL)
      }
    }
  }
}

cat("=== TOP 10 AIC ===\n")
print(resultats_sarima[order(resultats_sarima$AIC), ][1:10, ])

cat("=== TOP 10 BIC ===\n")
print(resultats_sarima[order(resultats_sarima$BIC), ][1:10, ])

mod_sarima <- Arima(serie$V2,
                   order      = c(3, 0, 3),

```

```

seasonal = list(order = c(0, 1, 1), period = 12))

print(mod_sarima$coef)

# Causalité
racines_AR <- Mod(polyroot(c(1, -mod_sarima$coef[1:3])))
cat("Racines AR :", racines_AR, "\n")
cat("Causal :", all(racines_AR > 1), "\n\n")

# Inversibilité MA
racines_MA <- Mod(polyroot(c(1, mod_sarima$coef[4:6])))
cat("Racines MA :", racines_MA, "\n")
cat("Inversible (MA) :", all(racines_MA > 1), "\n\n")

# Inversibilité SMA
racines_SMA <- Mod(polyroot(c(1, mod_sarima$coef[7])))
cat("Racines SMA :", racines_SMA, "\n")
cat("Inversible (SMA) :", all(racines_SMA > 1), "\n\n")

# Ljung-Box
Box.test(residuals(mod_sarima), lag=20, type="Ljung-Box")

predsarima <- predict(mod_sarima, n.ahead = 100)

predsarima$pred -> X_pred_sarima
temps=1001:1100
predict(mod_sarima, n.ahead = 100)

output <- data.frame(temps, X_pred_sarima)
write.table(output,
            file      = "???",
            row.names = FALSE,
            col.names = FALSE,
            sep       = " ")

library(forecast)

train_end_idx <- 900

```



```
h_forecast      <- 100

ts_train_full <- serie$V2[1:train_end_idx]
ts_test_full  <- serie$V2[(train_end_idx + 1):(train_end_idx + h_forecast)]
time_train    <- 1:train_end_idx
time_test     <- (train_end_idx + 1):(train_end_idx + h_forecast)

sarima_fit <- Arima(ts_train_full,
                    order      = c(3, 0, 3),
                    seasonal    = list(order = c(0, 1, 1), period = 12))

sarima_forecast_vec <- as.numeric(forecast(sarima_fit, h = h_forecast)$mean)

serie_ts_train <- ts(ts_train_full, frequency = 12)
decomp_train   <- decompose(serie_ts_train, type = "additive")

m_train <- as.numeric(decomp_train$trend)
s_train <- as.numeric(decomp_train$seasonal)

Y_train <- na.omit(ts_train_full - m_train - s_train)

arma_fit <- arima(Y_train, order = c(2, 0, 5))

arma_pred <- predict(arma_fit, n.ahead = 106)
Y_pred    <- as.numeric(arma_pred$pred)[7:106]

t_connu_train      <- 7:894
modele_tendance_train <- lm(m_train[7:894] ~ t_connu_train)
m_pred <- as.numeric(predict(modele_tendance_train,
                             newdata = data.frame(t_connu_train = time_test)))

s_values <- s_train[1:12]
s_pred   <- s_values[(time_test - 1) %% 12 + 1]

arma_forecast_vec <- m_pred + s_pred + Y_pred

plot(time_train, ts_train_full,
      type = "l",
```

```

col = "blue",
xlim = c(800, 1000),
ylim = range(c(ts_train_full, ts_test_full,
               sarima_forecast_vec, arma_forecast_vec), na.rm = TRUE),
xlab = "Temps",
ylab = "V2",
main = "SARIMA vs ARMA(2,5) vs Réel (Hold-out 100 points)")
lines(time_test, ts_test_full, col = "black", lwd = 2)
lines(time_test, sarima_forecast_vec, col = "red", lwd = 2)
lines(time_test, arma_forecast_vec, col = "darkgreen", lwd = 2)
legend("topleft",
      legend = c("Train", "Réel", "SARIMA(3,0,3)(0,1,1)12", "ARMA(2,5)"),
      col = c("blue", "black", "red", "darkgreen"),
      lty = 1,
      lwd = 1,      # réduit l'épaisseur des lignes dans la légende
      cex = 0.7,    # réduit la taille du texte
      bty = "n")    # supprime le cadre autour de la légende

mae <- function(y, yhat) mean(abs(y - yhat))
rmse <- function(y, yhat) sqrt(mean((y - yhat)^2))

mae_sarima <- mae(ts_test_full, sarima_forecast_vec)
rmse_sarima <- rmse(ts_test_full, sarima_forecast_vec)
mae_arma <- mae(ts_test_full, arma_forecast_vec)
rmse_arma <- rmse(ts_test_full, arma_forecast_vec)

results_metrics <- data.frame(
  Model = c("SARIMA(3,0,3)(0,1,1)12", "ARMA(2,5)"),
  MAE = c(mae_sarima, mae_arma),
  RMSE = c(rmse_sarima, rmse_arma)
)

print(results_metrics)

library(forecast)

```

```

debutts_test <- seq(501, 901, by = 50)

rmse <- function(y, yhat) sqrt(mean((y - yhat)^2))
mae <- function(y, yhat) mean(abs(y - yhat))

resultats_rolling <- data.frame()

for(train_end in debutts_test - 1){

  test_end <- train_end + 100
  if(test_end > 1000) break

  ts_train <- serie$V2[1:train_end]
  ts_test <- serie$V2[(train_end + 1):test_end]
  time_test_f <- (train_end + 1):test_end
  h <- length(ts_test)

  tryCatch({
    sarima_fit_r <- Arima(ts_train,
                        order = c(3, 0, 3),
                        seasonal = list(order = c(0, 1, 1), period = 12))
    sarima_pred_r <- as.numeric(forecast(sarima_fit_r, h = h)$mean)
  }, error = function(e) { sarima_pred_r <- rep(NA, h) })

  tryCatch({
    serie_ts_r <- ts(ts_train, frequency = 12)
    decomp_r <- decompose(serie_ts_r, type = "additive")
    m_r <- as.numeric(decomp_r$trend)
    s_r <- as.numeric(decomp_r$seasonal)
    Y_r <- na.omit(ts_train - m_r - s_r)

    arma_fit_r <- arima(Y_r, order = c(2, 0, 5))

    arma_pred_r <- predict(arma_fit_r, n.ahead = h + 6)
    Y_pred_r <- as.numeric(arma_pred_r$pred)[7:(h + 6)]

    t_connu_r <- 7:(train_end - 6)
    m_connu_r <- m_r[7:(train_end - 6)]
  }, error = function(e) { })
}

```

```

modele_tendance_r <- lm(m_connu_r ~ t_connu_r)
m_pred_r <- as.numeric(predict(modele_tendance_r,
                              newdata = data.frame(t_connu_r = time_test_f)))

s_values_r <- s_r[1:12]
s_pred_r   <- s_values_r[(time_test_f - 1) %% 12 + 1]

arma_pred_vec <- m_pred_r + s_pred_r + Y_pred_r

}, error = function(e) { arma_pred_vec <- rep(NA, h) })

resultats_rolling <- rbind(resultats_rolling, data.frame(
  Train_end    = train_end,
  Fenetre      = paste0(train_end + 1, ":", test_end),
  RMSE_SARIMA  = rmse(ts_test, sarima_pred_r),
  MAE_SARIMA   = mae(ts_test,  sarima_pred_r),
  RMSE_ARMA    = rmse(ts_test, arma_pred_vec),
  MAE_ARMA     = mae(ts_test,  arma_pred_vec)
))

cat("Fenêtre", train_end + 1, ":", test_end, "terminée\n")
}

print(resultats_rolling)

```